

Conociendo al Cliente 360°: Datos, Opiniones y Tendencias

Nombre del autor: Enzo A. Zambón

Email: enzo.a.zambon.16@gmail.com

Cohorte: PT01

Fecha de entrega: 28/08/2025

Contenido

Introducción.....	3
Desarrollo del proyecto.....	4
Avance 1: Conexión y limpieza de datos	4
Avance 2: Conexión y extracción de información a partir de la API	8
Avance 3: Analizar los datos integrados (clientes, Yelp, tendencias externas).....	9
Resultados principales y líneas futuras de análisis.....	11
Reflexión personal	Error! Bookmark not defined.

Introducción

InsightReach es una empresa de marketing digital especializada en campañas personalizadas para negocios locales. Con el crecimiento de su base de clientes y la expansión a nuevos mercados, la empresa busca optimizar su estrategia de segmentación para mejorar la efectividad de sus campañas.

El desafío es analizar, enriquecer e interpretar bases de datos complejas para generar recomendaciones accionables. Tu rol simula el trabajo de un profesional en un entorno real, donde deberás construir análisis sólidos, justificar decisiones y comunicar resultados de manera clara y estructurada.

Objetivos del PI:

- Explorar y comprender estructuras de datos relevantes provenientes de fuentes diversas.
- Aplicar técnicas de limpieza y transformación de datos para preparar datasets para análisis.
- Utilizar librerías de Python como pandas, numpy, matplotlib y seaborn para realizar análisis exploratorios de los datos (EDA)
- Conectar con una API externa (Yelp) para enriquecer un dataset con información contextual e implementar técnicas de web scraping para extraer datos relevantes de páginas web.
- Interpretar los resultados del análisis para generar recomendaciones accionables.
- Documentar el proceso de análisis de forma clara, estructurada y reproducible.

Desarrollo del proyecto

Avance 1: Conexión y limpieza de datos

Se comenzó con la carga y exploración inicial del dataset. Para ello, se importaron librerías (pandas, numpy) necesarias para el trabajo y cargamos el dataset de clientes.

Luego, se identificaron las ciudades y filtramos por una de interés: Boston. Se continuó con la exploración de la estructura: filas, columnas, tipos de datos y primeros registros.

El paso siguiente fue la limpieza y organización de los datos, a partir de la unificación de las columnas, su reordenamiento y la identificación de duplicados.

Se realizó un análisis de calidad de los datos, donde se identificaron columnas con información incompleta (edad, promedio_gasto_comida, preferencias_alimenticias, telefono_contacto, correo_electronico). También se realizó un proceso de validación de rangos y consistencia en las siguientes columnas:

- edad: encontramos valores extremos (ej: -5, 300).
- frecuencia_visita: detectamos inconsistencias (valores 0 y negativos).
- promedio_gasto_comida: valores menores o iguales a 0 (138 casos).
- ocio y consume_licor: correctos, solo contienen "Sí" / "No".
- ingresos_mensuales: no se detectaron problemas (en rango lógico).

Conclusiones preliminares:

El dataset requiere un proceso de normalización y limpieza para poder ser usado en análisis avanzados o recomendaciones.

- Variables con problemas principales:
 1. Edad (valores fuera de rango).
 2. Frecuencia de visita (valores inválidos).
 3. Promedio gasto comida (valores nulos o negativos).
 4. Preferencias alimenticias (datos faltantes).

5. Teléfono y correo electrónico (nulos).

Pasando de la detección de inconsistencias a la limpieza e imputación de datos, comenzamos por las variables numéricas:

1. Edad (edad):

- Se identificaron valores inválidos (-5, 300).
- Se reemplazaron por NaN y luego se imputaron con la mediana de grupos definidos por: `estrato_socioeconómico + promedio_gasto_comida + género`. Esto permitió asignar valores más realistas y no sesgar hacia la media general.

2. Frecuencia de visita (`frecuencia_visita`):

- Se detectaron valores en 0, los cuales fueron eliminados del dataset (no son visitas válidas), mientras que los valores en -3 fueron corregidos usando la mediana de frecuencia en función de: `estrato_socioeconómico + promedio_gasto_comida + edad`. Si no existía mediana para la combinación exacta, se aplicaba fallback progresivo hasta llegar a la mediana del estrato.

Para las variables categóricas:

1. Preferencias alimenticias (`preferencias_alimenticias`):

- Se detectaron nulos. Opciones analizadas: completar con la moda global (ej: "Vegetariano") o asignar en función de otras variables.
- Se optó por imputar usando la moda del grupo definido por: `estrato_socioeconómico + promedio_gasto_comida + edad`.
- Con fallback progresivo hasta llegar a la moda por estrato, y si no existía se imputaba como "Desconocido".

2. Teléfono de contacto y correo electrónico

- Se identificaron nulos, pero se definió dejarlos vacíos para no ocupar espacio en la memoria, ya que

Módulo 1

llenarlos con algún tipo de dato o valor podría no tener valor o incluso llevar a interpretaciones erróneas.

Como resultado, las columnas críticas (edad, frecuencia_visita, preferencias_alimenticias) quedaron normalizadas y sin inconsistencias graves. Se eliminó el sesgo de imputar con valores globales (media/moda) al usar variables relacionadas como referencia.

El dataset limpio de Boston se exportó como `df_clientes_boston.csv`

Finalmente se generaron tablas básicas para entender la distribución de variables como género, duración de sesión, calificaciones, etc.

1. Estratos de edad:

Se crearon rangos etarios: 18–30, 31–45, 46–60 y 60+. Esto permitió segmentar clientes y analizar patrones diferenciados de consumo.

2. Preferencias alimenticias por edad:

Se cruzaron los estratos de edad con las preferencias alimenticias.

Resultados destacados:

- 18–60 años preferencia por Vegetariano y Carnes.
- 60+ años mayor inclinación hacia Vegetariano y Mariscos, con menor proporción de carnes.
- También se calcularon proporciones relativas para entender la distribución dentro de cada grupo.

3. Distribución de género por edad:

Se generó una tabla cruzando estrato de edad vs género, donde se observó que el grupo +60 años es el que tiene mayor cantidad de personas en relación con los otros estratos.

4. Top 3 preferencias por edad y género

Se diseñó una función para extraer el Top 3 de preferencias alimenticias según edad + género.

Módulo 1

Hallazgos clave: En todos los segmentos, la moda es “Vegetariano”, mientras que el 2° y 3° lugar se reparte entre Carnes y Mariscos, dependiendo del grupo.

5. Nivel socioeconómico por edad

Se analizó la frecuencia de estratos socioeconómicos por edad, donde se concluyó que la moda en todos los rangos es “Alto”, seguido por Medio y luego Muy Alto.

Módulo 1

Avance 2: Conexión y extracción de información a partir de la API

Nos conectamos con la API de Yelp a partir de la `YELP_API_KEY` y definiendo como uno de los parámetros la ciudad = "Boston". Se pidieron 200 registros en lotes de 50 (offset) y para consolidarlos en un solo DataFrame `df_rest`.

Posteriormente se hizo una revisión inicial de los datos:

- Se verificaron los tipos
- Se detectaron valores nulos
- Se eliminaron columnas innecesarias (`image_url`, `is_closed`).
- Se verificó la duplicidad de la información, descartando esta posibilidad.

Luego se pasó a la normalización de las columnas:

- a) Normalización del precio: Originalmente "price" era categórico con símbolos (\$, \$\$, \$\$\$, \$\$\$\$), con lo cual se lo convirtió en escala numérica (1-4) en la columna "price_num". Algunos valores quedaron en NaN, los cuales fueron imputados con el promedio de su(s) categoría(s) a partir de la información provista por el resto de los restaurantes.

Finalmente se realizó un análisis de calidad de las reseñas, donde se concluyó que en `review_count` y `rating` no se presentan valores nulos ni negativos.

Por último, se guardó el dataset de restaurantes normalizado como `df_rest_boston.csv`.

Módulo 1

Avance 3: Analizar los datos integrados (clientes, Yelp, tendencias externas)

Se cargaron los datos importando los dataframes guardados: `df_clientes` (clientes en Boston) y `df_rest` (restaurantes de Boston, previamente trabajado).

Se procedió a la visualización y análisis descriptivo:

Tabla Clientes:

- Se realizaron las siguientes distribuciones:
 - a. Clientes por género y estrato socioeconómico
 - b. Promedio gasto en comida por estrato socioeconómico.
 - c. Frecuencia de visita por gasto promedio
 - d. Ingresos mensuales vs gasto en comida
 - e. Distribución de las preferencias alimenticias en la ciudad
 - f. Las preferencias alimenticias de los clientes con mayor gasto %
 - g. Porcentaje de distribución de la membresía premium
 - h. Consumo de alcohol según la edad
 - i. Frecuencia de visita por estrato de edad

Tabla de Restaurantes:

- Distribución de precios por restaurante: countplot sobre la variable `price_num` permite ver cuántos restaurantes hay en cada nivel de precios (1–4).
- Se creó un promedio ponderado por rating y cantidad de reseñas. Esto evita que un restaurante con pocas reseñas y rating 5.0 aparezca arriba injustamente. A partir de ello, se realizó un gráfico de barras horizontal con el top 10 de restaurantes en función de este promedio.
- Análisis por categorías: Se obtuvo la cantidad de restaurantes por categoría, y se visualizó un ranking de las 15 categorías más frecuentes
- Servicios ofrecidos: Se crearon columnas binarias a partir de los servicios ofrecidos (`pickup`, `delivery`, `reservation`), las cuales se vincularon el promedio ponderado y el nivel de

Módulo 1

precios para crear un mapa de calor que muestre las relaciones entre estas variables.

Para establecer conexiones entre ambos dataframes, Se creo una función de recomendaciones de restaurantes para cada cliente, en función de sus preferencias alimenticias, estrato economico y calidad del servicio.

- Compatibilidad económica (30%): La función `puede_pagar()` evalúa si un estrato socioeconómico puede pagar cierto `price_num` (1 a 4). Usa un diccionario de pesos, por ejemplo: Cliente "Bajo" tiene más probabilidad con restaurantes de precio 1 que de precio 4.
- Compatibilidad alimentaria (50%): La función `le_gusta_comida()` Mapea las preferencias del cliente (Carnes, Mariscos, Vegetariano, etc.) a un set de categorías del restaurante. Busca coincidencias entre `preferencias_alimenticias` del cliente y `categories_list` del restaurante. Si el match es fuerte, le asigna un score alto (0.6), mientras que si no hay coincidencia directa, lo hace con un score bajo (0.4)
- Calidad del restaurante (20%): La Función `calcular_calidad()` Basada en: `rating` normalizado (0–1) y la `review_count` normalizado (capado en 1000). Combina: 30% `rating` + 70% popularidad.

La Función principal: `recomendar_restaurantes(cliente_id, top_n=5)` filtra un cliente por `id_persona.`, itera sobre todos los restaurantes (`df_rest.iterrows()`) y calcula:

- `score_precio`
- `score_comida`
- `score_calidad`
- Y los combina en un `score_total` ponderado, devolviendo un DataFrame ordenado por score con las recomendaciones.

Finalmente, se realizaron distintas pruebas para verificar la validez del modelo, resultando en un modelo exitoso.

Resultados principales y líneas futuras de análisis

Resultados:

- Se logró integrar datos heterogéneos (clientes + restaurantes) de forma consistente y reproducible.
- El análisis exploratorio permitió comprender patrones de consumo, segmentar clientes y conocer la oferta gastronómica de Boston.
- El modelo de recomendación combina múltiples dimensiones (económica, alimentaria y calidad) logrando un enfoque realista y accionable.
- Todo el proceso quedó documentado y automatizado, permitiendo reproducibilidad y escalabilidad a otras ciudades.

Líneas futuras de avance:

Ampliación del dataset:

- Incorporar otras ciudades para comparar comportamientos y expandir la cobertura del modelo.
- Añadir variables externas: clima, eventos locales, tendencias gastronómicas.

Optimización del modelo de recomendación

- Ajustar ponderaciones de los factores según métricas de precisión (feedback de usuarios o tests A/B) o Incorporar técnicas de machine learning, como filtrado colaborativo o clustering de clientes.
- Mejorar la compatibilidad alimentaria usando procesamiento de lenguaje natural para categorizar menús.

Visualización y dashboard.

- Crear un dashboard interactivo con filtros por cliente, estrato, preferencia y rango de precios.
- Integrar mapas de geolocalización para mostrar restaurantes recomendados en Boston.
- Automatización y actualización
- Conectar de manera continua con la API de Yelp para mantener actualizadas las recomendaciones.

Módulo 1

- Establecer pipelines automáticos de limpieza y actualización de datos.

Evaluación y retroalimentación

- Implementar métricas de validación: coincidencia entre recomendaciones y elecciones reales de los clientes.
- Analizar la satisfacción del cliente para mejorar la ponderación de factores.